Toulouse INP - ENSEEIHT

Département des Sciences du Numérique

Projet long 2025-2026

Coachs Numériques combinant Intelligence Artificielle, Wearables et Souveraineté des Données

Supervisé par Riadh Dhaou

Badr Bikria
Damien Bonzom
Elisa Ciocarlan
Helia Galinier

Table des matières

1 Introduction **2**

2 Etat de l'art **2**
2.1 Motivations . . . 2
2.2 Panorama des applications de santé existantes . . . 2
2.2.1 Applications intégrées au téléphone . . . 2
2.2.2 Applications avec assistant LLM . . . 3
2.2.3 Applications de wearables . . . 3
2.3 Fonctionnalités clés . . . 4
2.3.1 Suivi du rythme cardiaque . . . 4
2.3.2 Suivi de la température cutanée . . . 4
2.3.3 Suivi du sommeil . . . 5
2.3.4 Suivi de l'activité physique . . . 5
2.3.5 Suivi des cycles menstruels . . . 6
2.3.6 Soutien en santé mentale . . . 6
2.3.7 Analyse des symptômes . . . 6
2.3.8 Mise en relation avec des professionnels de santé . . . 7
2.4 IA fédérée . . . 7
2.4.1 Fonctionnement général . . . 7
2.4.2 Principaux paradigmes du FL . . . 7
2.4.3 Algorithmes d'agrégation . . . 8
2.4.4 Frameworks potentiellement adaptés au projet . . . 8

3 Récupération des données **9**

4 Considérations légales et éthiques **9**

5 Conclusion **10**

6 Références **10**

1 Introduction

Ce rapport, rédigé dans le cadre de notre projet long, est consacré à l'étude et au développement de coachs numériques en santé. Notre objectif est de concevoir une solution innovante qui allie intelligence artificielle (IA), utilisation d'objets connectés tels que les wearables, et respect de la souveraineté des données.

Pour ce faire, nous dressons dans un premier temps un état de l'art complet du domaine : motivations, panorama des solutions existantes, fonctionnalités clés et introduction au concept d'IA fédérée. Nous analysons ensuite les protocoles techniques permettant l'extraction de données de santé issues des wearables. Enfin, nous clôturons ce document avec une analyse des enjeux éthiques et légaux, indispensable à la conception d'un outil appliqué à des données de santé.

2 Etat de l'art

2.1 Motivations

Ces dernières années, une augmentation de l'espérance de vie ainsi que de la prévalence de maladies chroniques a été observée. De plus, alors que la demande de soins de santé ne cesse de croître, l'accès à ces soins devient de plus en plus rare. C'est dans ce contexte qu'émerge le besoin en systèmes interactifs intelligents tels que des coachs numériques en santé pour assister les individus tout au cours de leur vie dans leur santé [1].

Le coaching en santé consiste à aider les patients à participer de manière active à leur bien-être en leur fournissant des connaissances et des outils afin qu'ils puissent atteindre les objectifs de santé qu'ils ont eux-même fixés [2]. Un coach en santé possède 5 rôles :

- Aide à l'autogestion : éduquer le patient selon ses besoins, l'aider à formuler des objectifs et à les accomplir
- Faire le lien entre le patient et le praticien
- Aider le patient à naviguer dans un système de santé
- Fournir du support émotionnel
- Faire un suivi du patient dans le temps

2.2 Panorama des applications de santé existantes

Dans cette partie, nous nous intéressons à différentes applications de santé générales déjà existantes. Nous faisons un panorama de ce qui existe déjà afin de mieux comprendre ce qu'on peut faire en plus. Trois catégories se distinguent : les applications de santé natives dans les téléphones du quotidien, les applications contenant des agents IA et les applications des wearables.

2.2.1 Applications intégrées au téléphone

Samsung et Apple étant les marques de téléphone les plus connues, nous nous intéressons à leur deux applications de santé respectives.

La première est "Samsung Health" [3]. Elle propose le suivi de plusieurs données : le nombre de pas (avec la durée et le nombre de calories brûlées), la durée du sommeil, la nutrition, le cycle menstruel, l'eau consommée, la pression artérielle, la glycémie, le stress, la fréquence cardiaque et le taux d'oxygène dans le sang. Avec une montre connectée, il est aussi possible de suivre l'indice AGE (mesure des produits terminaux de glycation avancée), l'indice antioxydant et la charge vasculaire. En terme d'activités, il est possible par exemple de suivre ses entraînements de marche, course, cyclisme, ect, ainsi que des exercices de respiration et de bien être. Des vidéos d'entraînement de fitness sont proposées avec un abonnement. Enfin, une sorte de système de réseau social est mis en place via le partage de défis avec une liste d'amis. En revanche aucune donnée personnelle n'est partagée avec ses amis.

La seconde application est "Apple Health" [4], qui comporte un grand nombre de catégories liées au suivi de santé comme l'activité physique, la nutrition, le sommeil, le bien-être mental, le cycle menstruel, le

cœur, l'audition, les mensurations et la respiration. Au sein de chacune de ces catégories, plusieurs données peuvent être analysées et différents scores sont produits. Certaines de ces catégories nécessitent des appareils connectés pour récolter les données, comme par exemple la catégorie "cœur", tandis que d'autres se basent uniquement sur les données captées par le téléphone, comme la catégorie audition qui indique l'exposition sonore ambiante. Parmi le large choix de fonctionnalités proposées, beaucoup d'entre elles nécessitent que l'utilisateur entre manuellement toutes ses données, et c'est notamment le cas des fonctionnalités liées au suivi de cycles menstruels. L'application "Apple Health" propose en outre de sauvegarder des éventuels symptômes, ses traitements en cours et ses documents médicaux. Si des traitements sont enregistrés, l'application envoie des rappels à l'utilisateur pour l'aider à les suivre correctement. Enfin, un résumé des données de santé généré par l'application peut être partagé à des proches ou a des professionnels de santé, mais de manière chiffrée et sans détails sur les données sensibles.

2.2.2 Applications avec assistant LLM

Pour les applications intégrant un agent IA, nous nous sommes intéressés à l'entreprise OpenAI qui a récemment sorti une version de ChatGPT dédiée à la santé. Nous avons aussi regardé l'entreprise Synapse Medicine, une entreprise française.

La première est donc "ChatGPT Health" [5]. Elle a été introduite le 7 janvier 2026 et est en cours de déploiement. Au moment où nous écrivons, elle est indisponible en France. Ils présentent cette application dont le but est de résoudre ce problème : "*Aujourd'hui, les informations de santé sont souvent dispersées entre des portails, des applications, des objets connectés, des PDF et des notes médicales, ce qui rend difficile une vision d'ensemble et laisse les personnes seules face à la complexité du système de santé.*". Ils insistent beaucoup sur la sécurité des données, primordiale dans ce contexte, notamment avec un chiffrement dédié et une isolation renforcée des données. Pour adapter le modèle d'IA dans un contexte de santé, ils ont travaillé avec 260 médecins afin d'obtenir plus de 600 000 avis sur les réponses du modèle, ce qui a permis d'adapter la façon de répondre : quand encourager à consulter un professionnel de santé, comment communiquer sans trop simplifier, comment encourager la sécurité dans une situation critique.

La principale fonctionnalité est de pouvoir importer ses données de santé, ses dossiers médicaux, se connecter avec "Apple Health", "Function Health", "MyFitnessPal", "Weight Watchers", "AllTrails", "Instacart" et "Peloton". Des exemples de prompts sont donnés comme : "*Comment évolue mon taux de cholestérol ?*" ou "*Peux-tu résumer mes derniers résultats d'analyses avant mon rendez-vous ?*".

La seconde application est "Synapse Medicine" [6], une solution française. Elle propose aux particuliers un agent IA appelé "MedGPT" qui donne une réponse médicale en citant ses sources. Leur solution majeure reste cependant destinée aux professionnels de santé avec "Synapse Copilote", qui les aide lorsqu'ils exercent leurs consultations médicales.

2.2.3 Applications de wearables

La dernière catégorie d'applications à regarder sont les applications des wearables. Étant donné que nous comptons en utiliser un, voir ce qui est déjà fait est utile. Nous nous intéressons à deux applications de deux entreprises de montres connectées : Fitbit et Withings.

La première application est "Fitbit" [7] de l'entreprise du même nom. Les fonctionnalités dépendent des montres. Un des derniers modèles peut suivre plusieurs éléments : la saturation en oxygène, la fréquence cardiaque, la conductance cutanée et la température cutanée. L'application propose aussi de suivre les pas, la durée du sommeil, le stress et la nutrition. Dans cette application, il est possible de se donner des objectifs à atteindre, et il existe une section "Coach" en proposant des séances de sport. Pour le côté social, il est possible d'ajouter ses enfants pour pouvoir consulter leur statistiques. Pour les amis, il est possible de partager les informations suivantes : date de naissance, genre, taille, poids, localisation, total des pas, distance parcourue et étages gravis.

La dernière application que nous regardons est "Withings" [8] de l'entreprise du même nom. D'après un des modèles récents, cette montre peut suivre la température en continu, la fréquence cardiaque, la qualité du sommeil, le niveau de saturation en oxygène dans le sang, la qualité respiratoire, les activités physiques et les

cycles menstruels. Au niveau de l'application, les fonctionnalités sont similaires. C'est sur l'aspect social qu'on observe des différences : il est possible de partager l'ensemble de ses données à ses proches. Il est également possible d'ajouter son enfant pour suivre ses données. Cette application propose en outre de faire le lien avec un professionnel de santé en offrant la possibilité de partager un rapport de santé. Enfin, il est possible de connecter d'autres applications pour mettre en lien les données.

2.3 Fonctionnalités clés

Dans cette section, nous présentons différentes fonctionnalités pouvant s'inscrire dans une application de coach numérique en santé, de manière à ce que l'application réponde aux cinq rôles identifiés dans la section 2.1.

2.3.1 Suivi du rythme cardiaque

Une donnée facilement récupérable avec des dispositifs portables est le rythme cardiaque. Plusieurs articles présentent des façons d'utiliser le rythme cardiaque pour détecter les anomalies afin de prévenir l'utilisateur.

Des études se concentrent sur des applications de santé appliquées au rythme cardiaque. Dans cet article [9] publié en 2024, un site internet propose de prédire le rythme cardiaque ainsi que des activités pour améliorer son mode de vie. Ils prédisent notamment le futur rythme cardiaque sur une durée de 10 jours afin de prédire les anomalies. Ils utilisent un modèle de machine learning de random forest. Ils recommandent des activités physiques (marche rapide, vélo, nage, ...) et des habitudes de vies (réduire la consommation de cigarettes, la consommation d'alcool, ...).

D'autres études se concentrent uniquement sur la prédiction du rythme cardiaque en utilisant les données des dispositifs portables. Dans cet article [10] paru en 2022, ils étudient différents algorithmes de machine learning : modèle ARIMA, régression linéaire, support vector regression, k-voisins plus proches, arbres de décision et random forest. Ils étudient aussi un modèle de deep learning : Long Short-Term Memory (LSTM). Un autre article [11] se concentre plus sur la différence en terme d'impact entre l'utilisation d'un modèle supervisé ou non-supervisé sur des données humaines.

D'autres études utilisent la prédiction du rythme cardiaque à d'autres finalités. Dans cet article [12], ils utilisent la prédiction du rythme cardiaque à partir des dispositifs portables pour analyser et prédire le niveau de stress et plus globalement la santé mentale.

2.3.2 Suivi de la température cutanée

Un autre type de données récupérables avec des dispositifs portables est la température cutanée, c'est-à-dire la température à la surface de la peau.

Certaines études s'intéressent au contrôle de la température ambiante en fonction de la température cutanée, notamment pour économiser de l'énergie. L'article [13] s'intéresse à prédire la demande thermale en utilisant un SVM. Ils proposent un prototype de contrôle intelligent de la température en utilisant ce prédicteur. Un autre article [14] prédit l'état thermal d'une personne (*Cool-Discomfort/Comfort/Warm-Discomfort*) à partir du rythme cardiaque et de la température cutanée.

D'autres projets mettent en place objets connectés pour calculer la température cutanée pour d'autres finalités. Par exemple le papier [15] propose de détecter des infections en amont. Ils utilisent trois types de récepteur pour détecter des anomalies dans la température cutanée ce qui serait signe d'infections. Ils font le lien entre l'objet connecté et le téléphone de l'utilisateur.

Enfin, la température peut servir d'indicateur pour les cycles menstruels (voir section 2.3.5). En effet, au cours d'un cycle, la température du corps au réveil est plus élevée pendant la phase lutéale que pendant les phases de menstruations, d'ovulation et la phase folliculaire.

2.3.3 Suivi du sommeil

Une des fonctions principales des nouvelles montres connectées est l'estimation du sommeil. Cette partie fait l'état de l'art sur ce qu'on peut extraire des montres connectées pour l'analyse du sommeil.

La première étape consiste à distinguer les périodes d'éveil et de sommeil à partir des signaux de la montre. Les approches de Van Hees et al. dans les deux articles [16] et [17], s'appuient uniquement sur les données brutes de l'accéléromètre intégré à la montre. Ces algorithmes détectent la fenêtre principale de sommeil en repérant la plus longue période nocturne où les changements d'orientation du bras restent faibles soit par des méthodes statistiques (HDBSCAN) ou par des règles (périodes d'inactivité soutenues). Ils détectent bien le sommeil, mais moins bien les périodes d'éveil pendant la nuit.

L'étape suivante est de pouvoir différencier les stades du sommeil (léger, profond,...). Cet aspect est plus complexe que le précédent, ainsi les modèles utilisés le seront aussi. Le problème a été abordé de deux manières différentes, avec et sans réseaux neuronaux.

Les deux articles, [18] et [19], concernent les méthodes sans réseaux neuronaux. Le premier utilise plus d'une quarantaine de règles et de caractéristiques intermédiaires pour extraire les stades du sommeil. Cependant, il manque plusieurs règles et caractéristiques pour pouvoir répliquer ce modèle. L'autre article propose un modèle de Markov caché pour extraire les phases de sommeil.

Ensuite, l'article [20] utilise le "Transfer Learning", une méthode utilisant les réseaux de neurones, pour différencier ces stades en utilisant l'accéléromètre et le rythme cardiaque. Malgré le fait qu'ils utilisent des technologies qui sont orientées sur la santé, on peut se demander si cette méthode est exportable sur les montres que nous avons car elle a prouvé avoir une meilleure performance que d'autres modèles. Cet article ne fournit pas le code, la base de données ni le modèle entraîné. Ainsi, il est difficile de répliquer ces résultats pour les appliquer à notre problématique.

Avec plusieurs semaines voire mois de données, il est aussi possible d'utiliser ces technologies dans le cadre d'analyse du sommeil pour certaines pathologies, ce qui pourrait être utile pour les praticiens. Dans cet article [21], ils recommandent d'utiliser ces données pour notamment détecter les insomnies. À noter que les données utilisées dans cette étude proviennent d'instruments médicaux et non d'une montre connectée grand public. Les résultats ne sont donc pas directement transférables tels quels à un dispositif commercial.

2.3.4 Suivi de l'activité physique

Une autre fonction prisée sur les montres connectées est la mesure de l'activité physique. Dans ce domaine, plusieurs mesures peuvent être effectuées notamment sur l'activité sportive, l'intensité qui y est associée, les dépenses énergétiques, la sédentarité et bien d'autres.

Un premier pas vers cela est le comptage de pas. Il existe plusieurs algorithmes mais celui choisi est un algorithme open source décrit dans ce papier [22]. La méthode, Verisense, utilise les données brutes de l'accéléromètre pour détecter des pics dans l'accélération. Le but est de récupérer ces pics puis de les filtrer pour enlever les artefacts liés aux autres activités quotidiennes.

La deuxième étape est de classer les activités physiques en fonction de leur intensité comme dans le papier [23]. Ils utilisent les données de l'accéléromètre et la fréquence cardiaque pour calculer un ou plusieurs scores. Le fait de prendre en compte la fréquence cardiaque peut être un avantage pour les sports dans lesquels les mouvements de bras sont moins sollicités ou ne reflètent pas l'intensité de l'activité. Ce score est ensuite seuillé pour connaître son intensité. Cette méthode semble pouvoir s'adapter aux données fournies par la montre et son efficacité a été prouvé par l'article.

2.3.5 Suivi des cycles menstruels

Les applications de santé telles que "Santé" d'Apple ou des applications spécialement dédiées au suivi des cycles menstruels proposent aux utilisatrices de sauvegarder leur historique de cycles et d'obtenir des prédictions sur leurs prochaines périodes de règles et de fertilité.

Pour faire de telles prédictions, la plupart des applications commercialisées s'appuient sur des données entrées manuellement par l'utilisatrice, comme la date des dernières règles, la durée moyenne des cycles et la durée moyenne des règles. L'application est ensuite régulièrement alimentée par l'utilisatrice qui peut indiquer lorsqu'elle a ses règles et les symptômes qu'elle peut observer : humeur, niveau d'énergie, aspects des sécrétions, température corporelle au réveil, qualité de la digestion du transit, libido etc.

Les algorithmes de prédiction de cycles menstruels et de fenêtres de fertilité se basent essentiellement sur la durée de cycle moyenne et la durée des périodes de règles, mais des méthodes prennent également en entrée la température basale et la fréquence cardiaque. Ces données peuvent être collectées via des outils dédiés, mais elles peuvent également être récupérées à l'aide de wearables sans que cela n'altère la qualité des prédictions [24]. Plusieurs types d'algorithmes peuvent être utilisés pour faire de la prédiction de données : modèles probabilistes, arbres de décisions, réseaux de neurones convolutifs et modèles de séries temporelles comme les LSTM. A ce jour, les réseaux LSTM semblent être les plus précis dans la prédiction des cycles menstruels [25]. Il est intéressant de noter que les données nécessaires à l'entraînement de ces modèles peuvent être générées grâce à des modèles probabilistes [26].

2.3.6 Soutien en santé mentale

Dans l'état de l'art, nous trouvons plusieurs manières de prendre en charge la santé mentale de l'utilisateur. Cela peut être fait via un chatbot comme décrit dans cet article [27]. Dans ce cas, la fonctionnalité se base sur des outils de traitement du langage naturel (NLP) et des Large Language Models (LLMs) afin que l'utilisateur puisse avoir une discussion avec l'outil.

Un autre article [28] propose de prendre en charge la santé mentale via un questionnaire soumis à l'utilisateur ayant pour but d'estimer le score PHQ-8. Ce score permet d'estimer le niveau de dépression chez l'individu. Ce même article propose également d'évaluer le risque de dépression et de suicide à l'aide de méthodes de NLP à partir du texte ou des enregistrements vocaux soumis par l'utilisateur dans l'application.

Comme indiqué dans la section 2.3.1, il est possible d'utiliser les données de montres de connectées afin de calculer un score de stress, qui est un indicateur de l'état de santé mentale d'un individu.

Il existe par ailleurs d'ores et déjà des applications exclusivement dédiées à la santé mentale telles que Replika, Flourish ou Anima. Ces applications proposent de faire du suivi de l'humeur et offrent des outils pour gérer le stress comme la méditation [29].

2.3.7 Analyse des symptômes

Dans [1], l'analyse des symptômes a un objectif double : proposer un diagnostic répondant à une liste de symptômes déclarés par l'utilisateur et le conseiller de consulter un médecin s'il est effectivement malade.

Le système décrit dans [1] est un chatbot utilisant du NLP pour comprendre la phrase écrite par l'utilisateur, et un réseau de neurones récurrent (RNN) pour reconnaître les symptômes dans la séquence de mots. Grâce à une base de données associant chaque maladie à une liste de symptômes, le chatbot peut expliquer à l'utilisateur sa maladie, ainsi que les mesures et médicaments à prendre pour s'en soigner.

L'article [30] adopte une approche différente en utilisant des modèles de langage plus avancés. Il propose deux architectures : MCN-BERT, qui combine le modèle de langage BERT avec une normalisation de concepts médicaux (MCN) qui permet d'associer plusieurs expressions médicales à un concept standardisé unique, et un modèle LSTM bidirectionnel. Ces modèles sont entraînés et évalués sur un dataset nommé *Symptoms2Disease* qui comporte 1200 paires symptômes/maladies sur 24 pathologies. Le modèle MCN-BERT optimisé avec AdamP atteint une précision de 99,58 %, surpassant d'après l'article les approches basées uniquement sur les RNN. Cependant, il est important de noter que ce dataset est limité en terme de diversité de population et

qu'aucune vérification en contexte clinique réel n'a été effectuée dessus.

L'analyse des symptômes peut donc être implémentée de façon assez naturelle et efficace, néanmoins certaines limites doivent être prises en compte : les symptômes rapportés par les utilisateurs peuvent être imprécis ou incomplets, et les modèles peuvent produire des résultats erronés ou anxiogènes s'ils sont mal calibrés. En notre qualité d'étudiants, nous n'avons aucun moyen de vérifier les informations prodiguées, et ce même si elle sont issues d'une base de données "fiable". Il serait ainsi plus sage de se limiter à la suggestion de consulter un professionnel.

2.3.8 Mise en relation avec des professionnels de santé

Parmi les rôles d'un coach numérique, deux d'entre eux consistent à aider le patient à naviguer dans un système de santé et à faire le lien entre lien avec les professionnels de santé. Une manière de répondre à ces deux objectifs consiste à mettre en relation l'utilisateur avec des professionnels de santé. L'article [1] propose de faire cela grâce à l'Overpass API [31]. Grâce à cette API, le système peut récupérer une liste d'établissements de santé pouvant répondre aux besoins médicaux de l'utilisateur situés dans la même zone géographique que celui-ci. Ainsi, l'application peut proposer différents cabinets, cliniques ou hôpitaux géographiquement accessibles et en adéquation avec les besoins de l'utilisateur. Les auteurs de l'article vont encore plus loin en proposant des consultations en ligne avec des professionnels de santé directement intégrés dans l'application.

2.4 IA fédérée

L'une des questions qu'il est légitime de se poser pour ce projet concerne le caractère privé des données communiquées par l'utilisateur au programme. Entraîner un modèle d'apprentissage profond à partir des données de tous les utilisateurs est risqué : le modèle étant très probablement trop complexe pour tourner sur un smartphone ou un navigateur web, il semble obligatoire de mettre en place un partage des données entre le serveur central réalisant les calculs et les différents moyens d'acquisition de ces dernières. Le meilleur moyen de pallier ce problème actuellement est l'IA fédérée (ou FL pour **F**ederated **L**earning).

2.4.1 Fonctionnement général

Les articles [32] et [33] font un état de l'art des frameworks de FL existants. D'après [32], le FL est une méthode de machine learning dans laquelle les données d'entraînement pour le modèle d'apprentissage sont isolées sur plusieurs serveurs d'hébergement de données, appelés agents. Un modèle est spécifié, puis entraîné localement sur chaque agent pendant plusieurs itérations. Ensuite, le modèle mis à jour sur chaque agent est partagé et agrégé dans un modèle global qui a été exposé à toutes les données disponibles, tandis que les données de chaque agent sont conservées localement et ne sont pas partagées entre les serveurs. Le modèle global est ensuite redistribué aux agents et entraîné pendant plusieurs itérations supplémentaires, et le processus se répète.

2.4.2 Principaux paradigmes du FL

En FL **horizontal**, chaque agent connaît une ou plusieurs lignes de la matrice de données d'apprentissage. En d'autres termes, chaque agent possède l'ensemble des données d'un ou plusieurs individus.

En FL **vertical**, chaque agent connaît une ou plusieurs colonnes complètes de la matrice de données d'apprentissage. En d'autres termes, chaque agent a des informations partielles sur l'ensemble des individus.

Le FL peut aussi être **centralisé** ou complètement **décentralisé**. Dans le premier cas, les agents communiquent avec un serveur central unique qui orchestre l'apprentissage. Dans les protocoles les plus simples, ce serveur est chargé d'agréger les modèles locaux et de diffuser le modèle global. Dans le dernier, il n'existe pas de serveur central : les agents communiquent directement les uns avec les autres et diffusent leurs modèles locaux en pair-à-pair.

2.4.3 Algorithmes d'agrégation

Si l'apprentissage est centralisé, le serveur peut combiner les modèles provenant des agents de diverses manières, dont les principales sont les suivantes :

— **FedAvg** : le modèle central agrège les modèles reçus en appliquant une moyenne des poids locaux, qui peut être pondérée par taille des jeux de donnée de chacun d'entre eux. C'est un algorithme simple et très utilisé, mais qui peut induire une divergence si les données sont trop hétérogènes.

— **FedProx** : une extension de FedAvg qui introduit un terme de régularisation proximale lors de l'entraînement local, contraignant les modèles locaux à rester proches du modèle global. Cette approche améliore la stabilité et la convergence en présence de données fortement hétérogènes.

— **FedOpt** : famille d'algorithmes dans lesquels l'agrégation côté serveur utilise des optimiseurs adaptatifs (comme Adam par exemple) au lieu d'une simple moyenne, permettant une convergence plus rapide et plus robuste sur des données non indépendantes et non identiquement distribuées.

2.4.4 Frameworks potentiellement adaptés au projet

Dans ce contexte, le choix du framework de FL constitue un enjeu central pour la faisabilité et la robustesse du système. L'étude comparative menée par [33] analyse en profondeur quinze frameworks open-source d'apprentissage fédéré selon des critères techniques, fonctionnels et ergonomiques, tels que la prise en charge des dispositifs mobiles et edge, les mécanismes de sécurité intégrés, la scalabilité et la facilité de déploiement. Les auteurs montrent qu'aucun framework ne couvre l'ensemble des besoins possibles, mais que certains se distinguent par leur polyvalence et leur maturité. En particulier, des frameworks comme **Flower** [34] et **FedML** [35] offrent un compromis favorable entre flexibilité, support des environnements hétérogènes (smartphones, objets connectés, serveurs), et capacité de déploiement en conditions réelles. Ces caractéristiques les rendent particulièrement adaptés aux applications de santé connectée, dans lesquelles les données issues de capteurs personnels (montres connectées, smartphones) doivent être traitées localement, tout en contribuant à l'entraînement collaboratif d'un modèle global respectueux de la confidentialité des utilisateurs.

Flower a l'avantage d'être agnostique vis-à-vis des frameworks de deep learning (PyTorch, TensorFlow, etc.). C'est-à-dire que n'importe quel modèle peut être réutilisé directement, sans modification majeure. Il est aussi possible d'utiliser ses propres algorithmes d'apprentissage. De plus, il supporte plusieurs algorithmes d'agrégation comme FedAvg, FedProx, FedOpt et plus encore. Flower permet enfin de simuler des agents à grande échelle (jusqu'à plusieurs millions) de façon assez réaliste pour refléter l'hétérogénéité des appareils utilisés sur une expérience réelle, et permet un continuum fluide entre la simulation et le déploiement réel (le même code pour un appareil simulé peut être utilisé sur de vrais appareils).

FedML présente grossièrement les mêmes avantages, aux différences suivantes près :

— FedML propose un support mobile/edge computing plus avancé, ainsi qu'un éventail plus large d'algorithmes de FL (horizontal, vertical, décentralisé, hierarchique, etc.)

— En contrepartie, FedML est plus complexe à prendre en main en raison du nombre élevé de fonctionnalités et de pipelines prédéfinis.

On peut aussi noter **EasyFL** [36], désigné comme étant le plus simple d'utilisation, qui se distingue par une prise en main rapide et une approche low-code facilitant le prototypage et l'expérimentation de scénarios de FL, mais dont les fonctionnalités restent limitées en termes de diversité des algorithmes (le seul disponible étant FedAvg). Ce framework propose plusieurs avantages :

— un nombre de ligne de code drastiquement réduit (3 lignes de code comparé à au moins une centaine pour d'autres frameworks) avec des commandes simples

— une API complète départagée en plusieurs objets pour utiliser le framework (model manager, data manager, simulation manager et tracking manager)

— possibilité de modifier le pipeline d'entraînement (chemin serveur-client-serveur) en modifiant certains modules, ou en reprenant des modules fait par d'autres personnes

Enfin, **FedKit** [37] se distingue par son orientation explicitement mobile, offrant un support natif pour les plateformes Android et iOS et facilitant l'intégration de l'apprentissage fédéré directement au sein d'applications

mobiles, ce qui en fait une solution particulièrement adaptée aux cas d'usage impliquant des smartphones et des objets connectés. Ce framework propose plusieurs avantages :

— un pipeline de machine learning cross-plateforme entre Android et IOS : conversion d'un modèle en TensorFlow pour Android et CoreML pour IOS, une API d'entraînement unifiée et une aggrégation cross-plateforme

— une gestion dynamique de l'application : modification dynamique du modèle utilisé dans l'application par un appel au backend (sinon il faut mettre à jour l'application à chaque changement de modèle) et une gestion flexible des serveurs avec le framework Flower

Une démonstration a été faite avec une application de santé utilisant des montres connectées, appelée "FedCampus", qui pourra servir de base à ce projet.

3 Récupération des données

Le but de cette partie est d'identifier les moyens de récupération des données des capteurs des différentes montres connectées.

Pour les montres connectées fonctionnant sur Wear OS, il est possible de développer et installer des applications directement sur la montre pour extraire les données des capteurs de la montre. Pour cela, il est possible d'activer le mode développeur sur la montre. Pour installer l'application sur la montre, il suffit de la connecter à un ordinateur via USB. L'application aura donc accès au capteur de la montre.

Pour les montres connectées Apple Watch, il faut avoir un compte développeur, qui est payant. Il n'est donc pas envisageable d'adapter notre application aux Apple Watch dans le cadre de ce projet.

Dans notre cas, nous disposons d'une montre Garmin qui ne fonctionne pas sous Wear OS. Néanmoins, Garmin possède son propre écosystème appelé Connect IQ. Pour développer une application, il suffit de télécharger Connect IQ SDK (https://developer.garmin.com/connect-iq/overview/) qui est gratuit. Le langage utilisé est Monkey C, spécifique à Garmin. Puis, pour tester l'application, il faut activer le mode "développeur" sur la montre puis la connecter à un ordinateur via USB pour télécharger l'application sur celle-ci. L'application peut ainsi directement avoir accès aux capteurs de la montre. Garmin a aussi développé une API pour avoir accès aux données de la montre. Il y a une API pour la santé et une pour l'activité physique. Les données accessibles ne sont pas les données brutes des capteurs mais les données déjà agrégées par des pré-traitement.

Dans le cas de la montre Scan Watch, il existe une API Withings (https://developer.withings.com/). Elle permet de récupérer les données des capteurs de la montre sous format JSON. Cependant, pour avoir accès à cette API, il faut faire plusieurs démarches d'enregistrement et de validation auprès de Withings ce qui peut constituer une contrainte supplémentaire.

En conclusion, l'un des aspects de notre application est la possibilité de rendre celle-ci compatible avec plusieurs montres. Cet aspect est compromis par la différence entre les différents écosystèmes des montres. Ces contraintes rendent l'intégration de montres de plusieurs fournisseurs plus complexe et coûteuse en temps. Ainsi, il paraît plus pertinent de se concentrer dans un premier temps sur l'intégration d'une seule montre et d'envisager selon l'avancement une extension à d'autres fournisseurs.

4 Considérations légales et éthiques

Lors de la mise au point d'un système interactif intelligent qui sera mis à disposition de la société, il y a plusieurs considérations légales et éthiques à prendre en compte, et d'autant plus lorsque l'outil a pour but d'intervenir directement dans la santé des utilisateurs.

Tout d'abord, une telle application de coach en santé risque de poser des soucis quant à la vie privée, étant donné que les utilisateurs vont fournir des données sensibles lors de son utilisation. Par exemple si l'application inclue un chatbot dont le fonctionnement est basé sur un Large Language Model, il y a des chances que des données sensibles soient collectées ou exposées par inadvertance, ce qui constituerait une violation de la vie privée. Afin de prévenir ce type de violations, le système doit être conçu de telle manière à ce que le règlement général sur la protection des données (RGPD) soit respecté. Par exemple, le système ne doit pas conserver les données de l'utilisateur plus longtemps que nécessaire.

Par ailleurs, un tel outil peut entraîner des dilemmes éthiques et des responsabilités juridiques s'il commet des erreurs qui causent un préjudice aux utilisateurs. Par le passé certains chatbots dédiés à la santé mentale se sont révélés n'être d'aucune aide avec des utilisateurs en crise, et les ont même encouragés à réaliser des actions portant atteinte à leur intégrité physique, voire à leur vie [29], et dans ce cas il est difficile de déterminer quel acteur porte la responsabilité. De ce fait, il faut s'assurer lors de la conception que les fonctionnalités de l'application ne soient pas directives et qu'elles ne puissent pas porter préjudice aux utilisateurs.

Les modèles d'IA contenus dans l'application sont entraînés sur des données pouvant contenir des biais, ce qui fait que l'application peut les perpétuer et ainsi causer des résultats discriminants pour certaines catégories de personnes. Une solution retenue pour réduire l'impact de ce biais est de s'assurer que les jeux de données utilisés pour l'entraînement des modèles soient les plus équitables.

Enfin, la mise à disposition d'un compagnon numérique risque de rendre certains utilisateurs dépendants. Cela peut causer la diminution du contact avec des humains chez ces individus, ou bien faire qu'ils négligent l'importance de consulter de l'aide médicale professionnelle. Afin de limiter ce risque, le système doit être conçu de telle manière à ce que l'utilisateur ne puisse pas développer de dépendance affective.

5 Conclusion

Pour conclure, ce document a souligné au travers de l'état de l'art les contributions majeures des coachs numériques de santé, en examinant les applications existantes et les fonctionnalités principales retrouvées dans ces dernières (suivi du sommeil, du cycle menstruel, etc.). Il a également démontré l'intérêt de l'IA fédérée pour enrichir ces services tout en considérant les enjeux de confidentialité et de protection des données.

En réalisant cet état de l'art, nous avons pu remarquer que la plupart des applications existantes traitent chaque focntionnalité proposée de manière isolée. Pour la suite de ce projet, nous souhaitons décloisonner les fonctionnalités afin de mieux refléter la réalité de la santé, où les différents paramètres (sommeil, activité, cycles) sont étroitement interdépendants.

6 Références

1. Radhamani, V., Devi, D. S., Blessie, E. C., Isabella Priya, P. J. & Tanushree, R. *HealthGuardian : Artificial Intelligence System for Early Diagnosis and Clinical Support* in *2025 International Conference on Computing and Communication Technologies (ICCCT)* (2025), 1-5. doi :10.1109/ICCCT63501.2025.11019623.
2. Bennett, H. D., Coleman, E. A., Parry, C., Bodenheimer, T. & Chen, E. H. Health coaching for patients with chronic illness. *Family practice management* **17,** 24-29 (2010).
3. Nov. 2025. https://www.samsung.com/fr/apps/samsung-health/.
4. https://www.apple.com/fr/health/.
5. https://openai.com/index/introducing-chatgpt-health/.
6. https://www.synapse-medicine.com/fr.
7. https://store.google.com/fr/magazine/fitbit_app?hl=fr.
8. https://www.withings.com/fr/fr/landing/withings-plus.
9. *European Journal of Medical and Health Sciences* **6,** 58-61. doi :10.24018/ejmed.2024.6.1.2009. https://eu-opensci.org/index.php/ejmed/article/view/42009 (fév. 2024).

10. Oyeleye, M., Chen, T., Titarenko, S. & Antoniou, G. A Predictive Analysis of Heart Rates Using Machine Learning Techniques. *International Journal of Environmental Research and Public Health* **19.** doi :10.3390/ijerph19042417. https://www.mdpi.com/1660-4601/19/4/2417 (2022).
11. Sabic, E., Keeley, D., Henderson, B. & Nannemann, S. Healthcare and anomaly detection : using machine learning to predict anomalies in heart rate data. *AI SOCIETY* **36.** doi :10.1007/s00146-020-00985-1 (mars 2021).
12. Coutts, L. V., Plans, D., Brown, A. W. & Collomosse, J. Deep learning with wearable based heart rate variability for prediction of mental and general health. *J. of Biomedical Informatics* **112.** doi :10.1016/j.jbi.2020.103610. https://doi.org/10.1016/j.jbi.2020.103610 (déc. 2020).
13. Dai, C., Zhang, H., Arens, E. & Lian, Z. Machine learning approaches to predict thermal demands using skin temperatures : Steady-state conditions. eng. **114,** 1-10 (2017).
14. Chaudhuri, T., Soh, Y. C., Li, H. & Xie, L. Machine learning driven personal comfort prediction by wearable sensing of pulse rate and skin temperature. *Building and Environment* **170,** 106615. doi :https://doi.org/10.1016/j.buildenv.2019.106615. https://www.sciencedirect.com/science/article/pii/S0360132319308285 (2020).
15. Huan, J., Bernstein, J. S., Difuntorum, P., Masna, N. V. R., Gravenstein, N., Bhunia, S. & Mandal, S. A Wearable Skin Temperature Monitoring System for Early Detection of Infections. eng. *IEEE sensors journal* **22,** 1670-1679 (2022).
16. Van Hees, V. T., Sabia, S., Jones, S. E., Wood, A. R., Anderson, K. N., Kivimäki, M., Frayling, T. M., Pack, A. I., Bucan, M., Trenell, M. I., Mazzotti, D. R., Gehrman, P. R., Singh-Manoux, B. A. & Weedon, M. N. Estimating sleep parameters using an accelerometer without sleep diary. en. *Sci. Rep.* **8,** 12975 (août 2018).
17. Van Hees, V. T., Sabia, S., Anderson, K. N., Denton, S. J., Oliver, J., Catt, M., Abell, J. G., Kivimäki, M., Trenell, M. I. & Singh-Manoux, A. A novel, open access method to assess sleep duration using a wrist-worn accelerometer. en. *PLoS One* **10,** e0142533 (nov. 2015).
18. Muzet, A., Werner, S., Fuchs, G., Roth, T., Saoud, J. B., Viola, A. U., Schaffhauser, J.-Y. & Luthringer, R. Assessing sleep architecture and continuity measures through the analysis of heart rate and wrist movement recordings in healthy subjects : comparison with results based on polysomnography. en. *Sleep Med.* **21,** 47-56 (mai 2016).
19. Mendez, M. O., Matteucci, M., Castronovo, V., Strambi, L. F., Cerutti, S. & Bianchi, A. M. Sleep staging from Heart Rate Variability : time-varying spectral features and Hidden Markov Models. *Int. J. Biomed. Eng. Technol.* **3,** 246 (2010).
20. Li, Q., Li, Q., Cakmak, A. S., Da Poian, G., Bliwise, D. L., Vaccarino, V., Shah, A. J. & Clifford, G. D. Transfer learning from ECG to PPG for improved sleep staging from wrist-worn wearables. en. *Physiol. Meas.* **42,** 044004 (mai 2021).
21. Smith, M. T., McCrae, C. S., Cheung, J., Martin, J. L., Harrod, C. G., Heald, J. L. & Carden, K. A. Use of actigraphy for the evaluation of sleep disorders and circadian rhythm sleep-wake disorders : An American academy of sleep medicine clinical practice guideline. en. *J. Clin. Sleep Med.* **14,** 1231-1237 (juill. 2018).
22. Maylor, B. D., Edwardson, C. L., Dempsey, P. C., Patterson, M. R., Plekhanova, T., Yates, T. & Rowlands, A. V. Stepping towards more intuitive physical activity metrics with wrist-worn accelerometry : Validity of an open-source step-count algorithm. en. *Sensors (Basel)* **22,** 9984 (déc. 2022).
23. Brage, S., Brage, N., Franks, P. W., Ekelund, U., Wong, M.-Y., Andersen, L. B., Froberg, K. & Wareham, N. J. Branched equation modeling of simultaneous accelerometry and heart rate monitoring improves estimate of directly measured physical activity energy expenditure. en. *J. Appl. Physiol.* **96,** 343-351 (jan. 2004).
24. Luo, C., Su, Y.-F., Ren, Y.-Y., Zhang, Q., Li, R., Zhang, Q., Li, C., Hao, Y.-H., Zhang, A.-Q., Zhang, H., Huang, H.-F. & Wu, Y.-T. Prediction of the fertile window and menstruation with a wearable device via machine-learning algorithms. *Reproductive BioMedicine Online* **51,** 104795. doi :https://doi.org/10.1016/j.rbmo.2025.104795. https://www.sciencedirect.com/science/article/pii/S1472648325000021 (2025).

25. Khairunisa, M., Putri, D. M. S. A. & Wijayakusuma, I. G. N. L. Comparison of Machine Learning Methods for Menstrual Cycle Analysis and Prediction. *Journal of Applied Informatics and Computing* **9,** 348-353 (2025).
26. Rego, R. C. B. *Predictive Modeling of Menstrual Cycle Length : A Time Series Forecasting Approach* 2023. arXiv : 2308.07927 [cs.LG]. https://arxiv.org/abs/2308.07927.
27. Oghenekaro, L. & Okoro, C. Artificial Intelligence-Based Chatbot for Student Mental Health Support. *OALib* **11,** 1-16. doi :10.4236/oalib.1111511 (jan. 2024).
28. Siu, V. S., Hsieh, K. Y., Buleje, I., Itoh, T., Hao, T., Civjan, B., Hinds, N., Dang, B., Rogers, J. L. & Wen, B. *Health Guardian : Using Multi-modal Data to Understand Individual Health* in *2023 IEEE International Conference on Digital Health (ICDH)* (2023), 65-74. doi :10.1109/ICDH60066.2023.00019.
29. Freitas, J. & Cohen, I. The health risks of generative AI-based wellness apps. *Nature Medicine* **30.** doi :10.1038/s41591-024-02943-6 (avr. 2024).
30. Hassan, E., Abd El-Hafeez, T. & Shams, M. Y. Optimizing classification of diseases through language model analysis of symptoms. *Scientific Reports* **14.** doi :10.1038/s41598-024-51615-5. http://dx.doi.org/10.1038/s41598-024-51615-5 (jan. 2024).
31. Wiki, O. *Overpass API — OpenStreetMap Wiki* [Online ; accessed 3-February-2026]. 2026. https://wiki.openstreetmap.org/w/index.php?title=Overpass_API&oldid=2947309.
32. Clark, P., Oermann, E. K., Chen, D. & Al-Aswad, L. A. Federated AI, Current State, and Future Potential. *Asia-Pacific Journal of Ophthalmology* **12,** 310-314. doi :https://doi.org/10.1097/APO.0000000000000614. https://www.sciencedirect.com/science/article/pii/S2162098923008071 (2023).
33. Riedel, P., Schick, L., von Schwerin, R., Reichert, M., Schaudt, D. & Hafner, A. Comparative analysis of open-source federated learning frameworks - a literature-based survey and review. *International Journal of Machine Learning and Cybernetics* **15,** 5257-5278. doi :10.1007/s13042-024-02234-z. http://dx.doi.org/10.1007/s13042-024-02234-z (juin 2024).
34. Beutel, D. J., Topal, T., Mathur, A., Qiu, X., Fernandez-Marques, J., Gao, Y., Sani, L., Li, K. H., Parcollet, T., de Gusmão, P. P. B. & Lane, N. D. Flower : A Friendly Federated Learning Research Framework. doi :10.48550/ARXIV.2007.14390. https://arxiv.org/abs/2007.14390 (2020).
35. He, C., Li, S., So, J., Zeng, X., Zhang, M., Wang, H., Wang, X., Vepakomma, P., Singh, A., Qiu, H., Zhu, X., Wang, J., Shen, L., Zhao, P., Kang, Y., Liu, Y., Raskar, R., Yang, Q., Annavaram, M. & Avestimehr, S. *FedML : A Research Library and Benchmark for Federated Machine Learning* 2020. doi :10.48550/ARXIV.2007.13518. https://arxiv.org/abs/2007.13518.
36. Zhuang, W., Gan, X., Wen, Y. & Zhang, S. EasyFL : A Low-Code Federated Learning Platform for Dummies. *IEEE Internet of Things Journal* **9,** 13740-13754. doi :10.1109/jiot.2022.3143842. http://dx.doi.org/10.1109/JIOT.2022.3143842 (août 2022).
37. He, S., Tang, B., Zhang, B., Shao, J., Ouyang, X., Nugraha, D. N. & Luo, B. FedKit : Enabling Cross-Platform Federated Learning for Android and iOS. doi :10.48550/ARXIV.2402.10464. https://arxiv.org/abs/2402.10464 (2024).